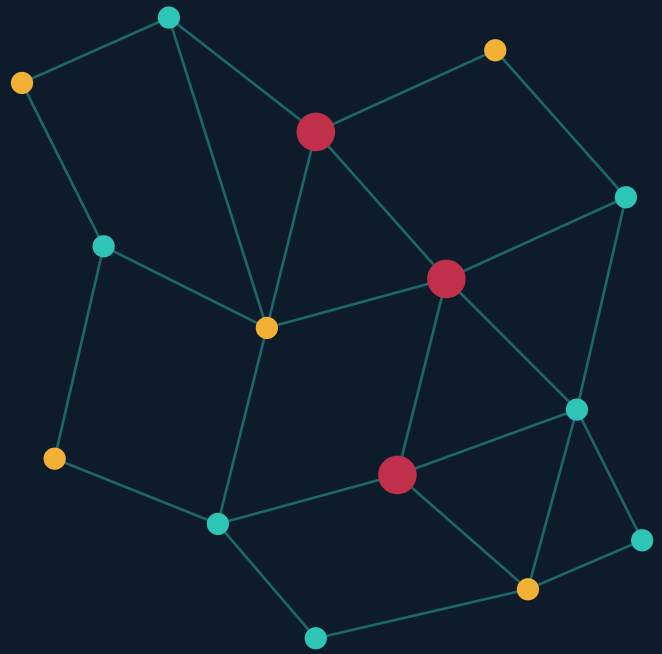
ΕΒΔΟΜΑΔΑ 6 · ΕΝΟΤΗΤΑ 2

Εισαγωγή στην Οικονομετρία

Βασικές έννοιες & χρονοσειρές · απλή & πολλαπλή γραμμική παλινδρόμηση · πόσες πωλήσεις φέρνει η διαφήμιση;



Δρ. Αθανάσιος Κρανιάς
Βάσεις Δεδομένων & Επιχειρηματική Αναλυτική · Τμήμα Χρηματοοικονομικής και Τραπεζικής Διοικητικής · Πανεπιστήμιο Πειραιώς

Πού είμαστε

Η SQL μάς έδωσε τα δεδομένα · η οικονομετρία μάς δίνει τις απαντήσεις

εβδ. 1–5 ✓

SQL

Εξαγωγή & σύνθεση

εβδ. 6–8 **σήμερα**

Οικονομετρία

Μοντέλα & έλεγχοι

εβδ. 9–13

R & Power BI

End-to-end ανάλυση

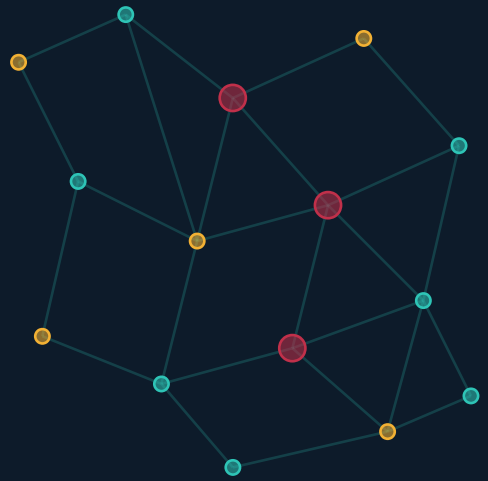
Σήμερα θα μάθεις να:

- ξεχωρίζεις διαστρωματικά δεδομένα, χρονοσειρές και panel
- διατυπώνεις ένα επιχειρηματικό ερώτημα ως μοντέλο
- εκτιμάς και ερμηνεύεις μια απλή παλινδρόμηση
- μετράς πόσα € πωλήσεων φέρνει 1 € διαφήμισης
- εκτιμάς πολλαπλή παλινδρόμηση στην R με lm()

01

Τα βασικά της οικονομετρίας

Τι είναι · πληθυσμός & δείγμα · τύποι δεδομένων · χρονοσειρές · μεταβλητές · περιγραφικά στατιστικά



Τι είναι η οικονομετρία;

Οικονομική θεωρία + στατιστική + δεδομένα → αριθμοί, με μέτρο αβεβαιότητας

Οικονομική θεωρία

Τι περιμένουμε να δούμε: περισσότερη διαφήμιση → περισσότερες πωλήσεις.

+

Στατιστική

Πώς το μετράμε — και πόσο σίγουροι μπορούμε να είμαστε για το αποτέλεσμα.

+

Δεδομένα

Τι συνέβη πραγματικά: οι 731 ημέρες της UniStyle, όπως τις έβγαλε η SQL.

= Οικονομετρία: ποσοτικές απαντήσεις σε οικονομικά και επιχειρηματικά ερωτήματα, με βάση τα δεδομένα

Μέτρηση

Πόσο; Πόσα € πωλήσεων φέρνει 1 € διαφήμισης;

β = 4,08

Έλεγχος υποθέσεων

Ισχύει; Είναι το 4,08 πραγματικά πάνω από το 2 ή τύχη;

εβδ. 7

Πρόβλεψη

Τι θα γίνει; Πόσα θα πουλήσουμε μια ημέρα με 150 € διαφήμιση;

≈ 663 €

Από την επιχειρηματική ερώτηση στο μοντέλο

Η οικονομετρία μετατρέπει το «πόσο;» σε αριθμό — με μέτρο αβεβαιότητας

Ερώτηση της διοίκησης της UniStyle	Μοντέλο	Θα το δούμε
Πόσες πωλήσεις φέρνει 1 € διαφήμισης;	Πωλήσεις = $\beta_0 + \beta_1 \cdot$ Διαφήμιση	σήμερα
Αξίζει να στέλνουμε newsletter;	Πωλήσεις = $\beta_0 + \beta_1 \cdot$ Διαφήμιση + $\beta_2 \cdot$ Newsletter + …	σήμερα
Η διαφήμιση φέρνει κέρδος ή μόνο πωλήσεις;	Έλεγχος: είναι το β_1 μεγαλύτερο από 2;	εβδ. 7
Μπορώ να εμπιστευτώ τα αποτελέσματα;	Διαγνωστικοί έλεγχοι	εβδ. 8

Στην τράπεζα: μοντέλα πιστωτικού κινδύνου, stress tests, αποτίμηση — όλα ξεκινούν από την ίδια ιδέα.

Πληθυσμός, δείγμα, εκτιμητής

Βλέπουμε ένα κομμάτι της πραγματικότητας — και από αυτό συμπεραίνουμε για το σύνολο

Πληθυσμός

Όλες οι ημέρες λειτουργίας της UniStyle — παρελθόν, παρόν και μέλλον. Δεν τον βλέπουμε ποτέ ολόκληρο.

εκτίμηση ←

Δείγμα

Οι 731 ημέρες (2024–2025) που έχουμε στη βάση UniStyleDB. Από αυτές υπολογίζουμε ό,τι μπορούμε.

Μέγεθος	Στον πληθυσμό: παράμετρος (άγνωστη)	Στο δείγμα: εκτιμητής (τον υπολογίζουμε)
Μέσος όρος	μ	$\bar{x}$ («χ παύλα»)
Τυπική απόκλιση	σ	s
Κλίση παλινδρόμησης	β_1	$\hat{\beta}_1$ («βήτα καπέλο»)

Άλλο δείγμα → άλλη εκτίμηση: με τις ημέρες του 2024 βγαίνει $\hat{\beta}_1 = 3{,}99$, με του 2025 $\hat{\beta}_1 = 4{,}16$. Πόσο «χορεύει» η εκτίμηση το μετράει το τυπικό σφάλμα (εβδ. 7).

Τρεις τύποι δεδομένων

Ποιος, πότε ή και τα δύο — η μορφή των δεδομένων καθορίζει το μοντέλο

Διαστρωματικά

cross-section

Πολλές μονάδες · μία χρονική στιγμή · δείκτης i (π.χ. πελάτης)

UniStyle: Customers: 400 πελάτες με ηλικία, πόλη, newsletter

Τράπεζα / αγορές: Οι πελάτες δανείων μιας τράπεζας στις 31/12

```
GROUP BY CustomerID
```

Χρονοσειρά

time series

Μία μονάδα · πολλές διαδοχικές στιγμές · δείκτης t (π.χ. ημέρα)

UniStyle: UniStyle_Daily: 731 ημέρες πωλήσεων και διαφήμισης

Τράπεζα / αγορές: Τιμή μετοχής, επιτόκιο, πληθωρισμός, ΑΕΠ

```
GROUP BY OrderDate
```

Panel

πάνελ δεδομένα

Πολλές μονάδες · πολλές στιγμές · δείκτες i και t

UniStyle: Πωλήσεις ανά κατηγορία ανά μήνα: 10 × 24 = 240 γραμμές

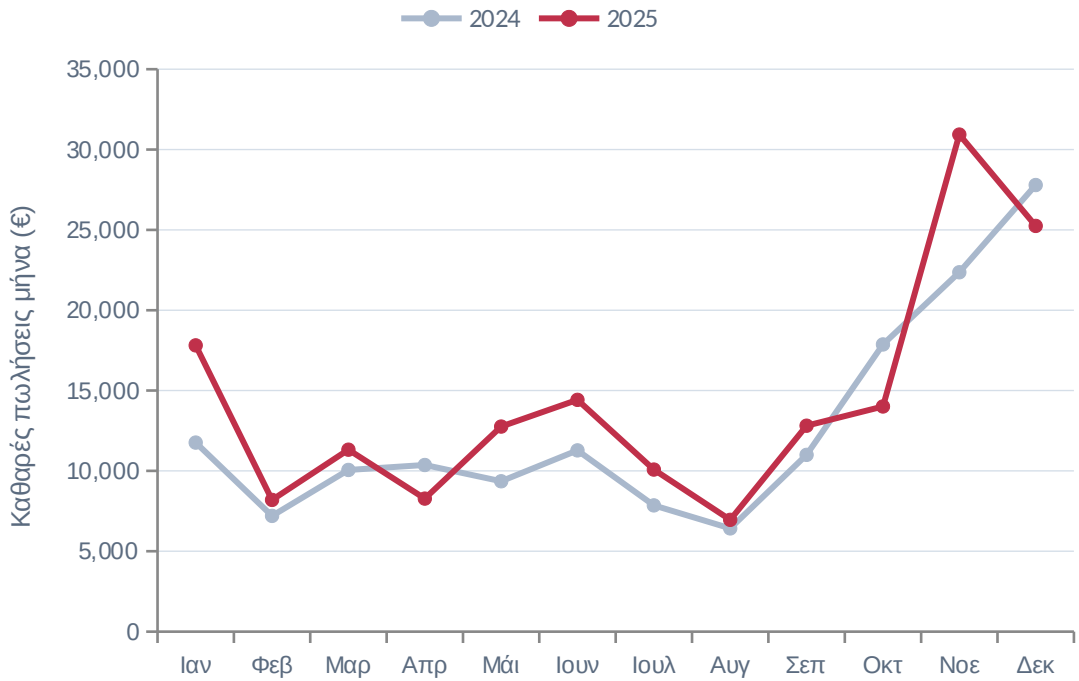
Τράπεζα / αγορές: Υπόλοιπο κάθε δανείου κάθε μήνα

```
GROUP BY Category, Month
```

Η SQL αποφασίζει τον τύπο: το ίδιο OrderItems γίνεται διαστρωματικό, χρονοσειρά ή panel ανάλογα με το GROUP BY. Στις εβδ. 6–8 δουλεύουμε με χρονοσειρά.

Τι είναι η χρονοσειρά;

Οι τιμές μιας μεταβλητής σε διαδοχικές, ισαπέχουσες χρονικές στιγμές



Χρονοσειρά

$y_1, y_2, y_3, \ldots, y_{731}$

Η σειρά των γραμμών έχει σημασία — δεν τις ανακατεύουμε όπως τους πελάτες.

Συχνότητα

Ημερήσια: πωλήσεις eshop, μετοχές

Μηνιαία: πληθωρισμός, ανεργία

Τριμηνιαία: ΑΕΠ, αποτελέσματα εταιρειών

Ετήσια: προϋπολογισμός

Τι «κρύβει» μια χρονοσειρά

Τέσσερα συστατικά — και τα εργαλεία που θα συναντάμε συνέχεια

Τάση *trend*

2025: +12,7% πάνω από το 2024 (153.306 → 172.812 €)

Εποχικότητα *seasonality*

Κάθε χρόνο κορυφή Νοέμβριο–Δεκέμβριο, «βουτιά» τον Αύγουστο

Κύκλος *cycle*

Ανεβοκατεβάσματα της οικονομίας που κρατούν χρόνια — 2 χρόνια δεν φτάνουν να τα δούμε

Θόρυβος *noise*

Ό,τι μένει: η «τύχη» κάθε ημέρας που κανένα μοντέλο δεν προβλέπει

Εργαλείο	Τύπος	Τι σημαίνει στη UniStyle
Υστέρηση (lag)	`y(t−1)`	Οι χθεσινές πωλήσεις, στη γραμμή της σημερινής ημέρας
Μεταβολή	`Δy(t) = y(t) − y(t−1)`	Πόσα € περισσότερα πουλήσαμε από χθες
% μεταβολή · απόδοση	`(y(t) − y(t−1)) / y(t−1)`	Οι αποδόσεις (returns) των μετοχών των εβδ. 1–4
Αυτοσυσχέτιση	`cor(y(t), y(t−1))`	0,40: μια «καλή» ημέρα συνήθως ακολουθείται από καλή

Τύποι μεταβλητών

Τι εξηγούμε, με τι το εξηγούμε — και τι είδους αριθμός είναι η κάθε στήλη

y εξαρτημένη

ή ερμηνευόμενη · στο machine learning: target

x ανεξάρτητες

ή ερμηνευτικές · στο machine learning: features

Στήλη (UniStyle_Daily)	Τύπος μεταβλητής	Τιμές	Σχόλιο
Revenue, AdSpend	Συνεχής	0 – 2.995 €	Μπορεί να πάρει οποιαδήποτε τιμή
Orders	Διακριτή (πλήθος)	0, 1, 2, …, 30	Μετράμε — δεν υπάρχει 2,5 παραγγελία
Weekend, EmailCampaign, BlackFriday	Ψευδομεταβλητή (dummy)	0 / 1	Ναι ή όχι · ο συντελεστής = διαφορά «ναι – όχι»
Month	Κατηγορική	1 – 12	Ο αριθμός είναι ετικέτα: ο 12 δεν είναι «διπλάσιος» του 6
Date	Χρονικός δείκτης (t)	1/1/2024 – 31/12/2025	Ορίζει τη σειρά της χρονοσειράς

Περιγραφικά στατιστικά

Πριν από κάθε μοντέλο: «γνωρίζουμε» τα δεδομένα · UniStyle_Daily, 731 ημέρες

Μέτρο	Τύπος	Τι σημαίνει	Revenue (€)	AdSpend (€)
Μέσος όρος	`x̄ = Σx / n`	Το σύνολο μοιρασμένο εξίσου σε κάθε ημέρα. Τον «τραβούν» οι ακραίες τιμές.	446,13	96,88
Διάμεσος	`η μεσαία τιμή`	Οι μισές ημέρες πούλησαν λιγότερο, οι μισές περισσότερο. Δεν τον επηρεάζουν οι ακραίες.	348,94	84,62
Τυπική απόκλιση	`s = √[Σ(x − x̄)² / (n − 1)]`	Πόσο απέχει «συνήθως» μια ημέρα από τον μέσο όρο — η διασπορά, σε €.	385,40	65,91
Ελάχιστο – μέγιστο	`min(x) – max(x)`	Το εύρος: 0 € = ημέρα χωρίς παραγγελίες, 2.995 € = Black Friday.	0 – 2.994,80	8,14 – 592,03
Συνδιακύμανση	`Σ(x − x̄)(y − ȳ) / (n − 1)`	Το πρόσημο λέει αν κινούνται μαζί (+) ή αντίθετα (−). Το μέγεθος εξαρτάται από τις μονάδες.	17.743,84	
Συσχέτιση	`r = cov(x, y) / (s_x · s_y)`	Η συνδιακύμανση «χωρίς μονάδες», από −1 έως 1. 0,70 = ισχυρή θετική σχέση.	0,70	

Στην R: `mean()` · `median()` · `sd()` · `min()` / `max()` · `cov()` · `cor()` — ή τα περισσότερα μαζί με `summary()`

Μέσος (446 €) > διάμεσος (349 €): λίγες πολύ «καλές» ημέρες τραβούν τον μέσο προς τα πάνω — δεξιά ασυμμετρία.
Από αυτά φτιάχνεται η κλίση: $\hat{\beta_1}$ = cov(x, y) / s^2_x = 17.743,84 / 65,91² = 17.743,84 / 4.344,72 = 4,08 (Άσκηση 3).

Συσχέτιση, παλινδρόμηση, αιτιότητα

Τρεις έννοιες που συχνά μπερδεύονται

Συσχέτιση

$r \in [-1, 1]$

Πόσο «μαζί» κινούνται δύο μεταβλητές. Συμμετρική: cor(x, y) = cor(y, x).

cor = 0.70 (πωλήσεις & διαφήμιση)

Παλινδρόμηση

$y = \beta_0 + \beta_1 x + u$

Πόσο αλλάζει το y όταν το x αλλάζει κατά 1. Έχει κατεύθυνση: εξηγούμε το y με το x.

β = 4.08

Αιτιότητα

$x \rightarrow y$

Το x προκαλεί το y. Δεν προκύπτει αυτόματα από τα δεδομένα — χρειάζεται θεωρία ή πείραμα.

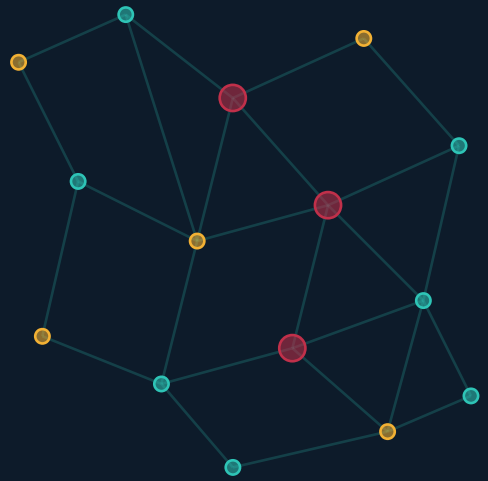
«Παγωτά & πνιγμοί»

Τα καλοκαίρια πουλιούνται περισσότερα παγωτά και συμβαίνουν περισσότεροι πνιγμοί — η κοινή αιτία είναι η ζέστη.

02

Απλή γραμμική παλινδρόμηση

Μία εξαρτημένη, μία ανεξάρτητη μεταβλητή



Το μοντέλο

Μια ευθεία που περιγράφει τη σχέση — και ένας όρος για ό,τι δεν εξηγεί

$$y = \beta_0 + \beta_1 \cdot x + u$$

y	**Εξαρτημένη μεταβλητή**	Αυτό που θέλουμε να εξηγήσουμε (ημερήσιες πωλήσεις)
x	**Ανεξάρτητη (ερμηνευτική)**	Αυτό που εξηγεί (δαπάνη διαφήμισης της ημέρας)
β_0	**Σταθερός όρος**	Η τιμή του y όταν x = 0
β_1	**Κλίση**	Μεταβολή του y όταν το x αυξάνεται κατά 1
u	**Σφάλμα (κατάλοιπο)**	Ό,τι επηρεάζει το y αλλά δεν είναι στο μοντέλο (εποχή, καιρός, τύχη…)

Πώς βρίσκουμε την «καλύτερη» ευθεία;

Μέθοδος Ελαχίστων Τετραγώνων (Ordinary Least Squares, OLS)

Κατάλοιπο: η κάθετη απόσταση κάθε σημείου από την ευθεία: $\hat{u}_i = y_i - \hat{y}_i$

OLS: διαλέγει β_0, β_1 ώστε το άθροισμα των τετραγώνων των καταλοίπων να είναι το ελάχιστο

Γιατί τετράγωνα; θετικά και αρνητικά λάθη δεν αλληλοαναιρούνται · τα μεγάλα λάθη «τιμωρούνται» περισσότερο

Οι τύποι

$$\hat{\beta}_1 = \mathrm{Cov}(x, y) / \mathrm{Var}(x)$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \cdot \bar{x}$$

Δεν θα τα υπολογίζουμε με το χέρι — το κάνει η R (και το Excel).

Στο Excel: =SLOPE(y; x) δίνει το $\hat{\beta}_1$, =INTERCEPT(y; x) το $\hat{\beta}_0$, =RSQ(y; x) το R^2. Για πλήρη αποτελέσματα: Data → Data Analysis → Regression.

Πρώτα: από παραγγελίες σε ημερήσια δεδομένα

Για να μετρήσουμε την επίδραση της διαφήμισης, χρειαζόμαστε μία γραμμή ανά ημέρα

Date	Orders	Revenue	AdSpend	EmailCampaign
2024-01-01	1	93.98	8.59	0
2024-01-02	2	289.96	41.23	0
2024-01-03	3	351.95	81.57	0
…	…	…	…	…

Οι πρώτες γραμμές του UniStyle_Daily.csv · 731 γραμμές (2024–2025)

Revenue: SUM των γραμμών παραγγελιών της ημέρας (Orders + OrderItems, μόνο Delivered)

AdSpend: SearchAds + SocialAds από τον νέο πίνακα DailyMarketing

EmailCampaign: 1 αν στάλθηκε newsletter εκείνη την ημέρα

Weekend, BlackFriday: 0/1 από την ημερομηνία

Νέος πίνακας στη βάση: DailyMarketing. Μία γραμμή ανά ημέρα, με τη δαπάνη διαφήμισης σε Google (SearchAds) και social media (SocialAds) και το newsletter. Συνδέεται με τις παραγγελίες μέσω της ημερομηνίας.

Το ερώτημα: αξίζει η διαφήμιση;

Η πρώτη μας παλινδρόμηση — και το «νεκρό σημείο» του marketing

$$\text{Revenue} = \beta_0 + \beta_1 \cdot \text{AdSpend} + u$$

$\beta_1 > 2$

Κερδοφόρα

Κάθε 1 € διαφήμισης φέρνει πάνω από 2 € πωλήσεις — αρκετά για να καλύψει το κόστος του

$\beta_1 = 2$

Νεκρό σημείο

Το μικτό κέρδος από τις νέες πωλήσεις ίσα-ίσα πληρώνει τη διαφήμιση

$\beta_1 < 2$

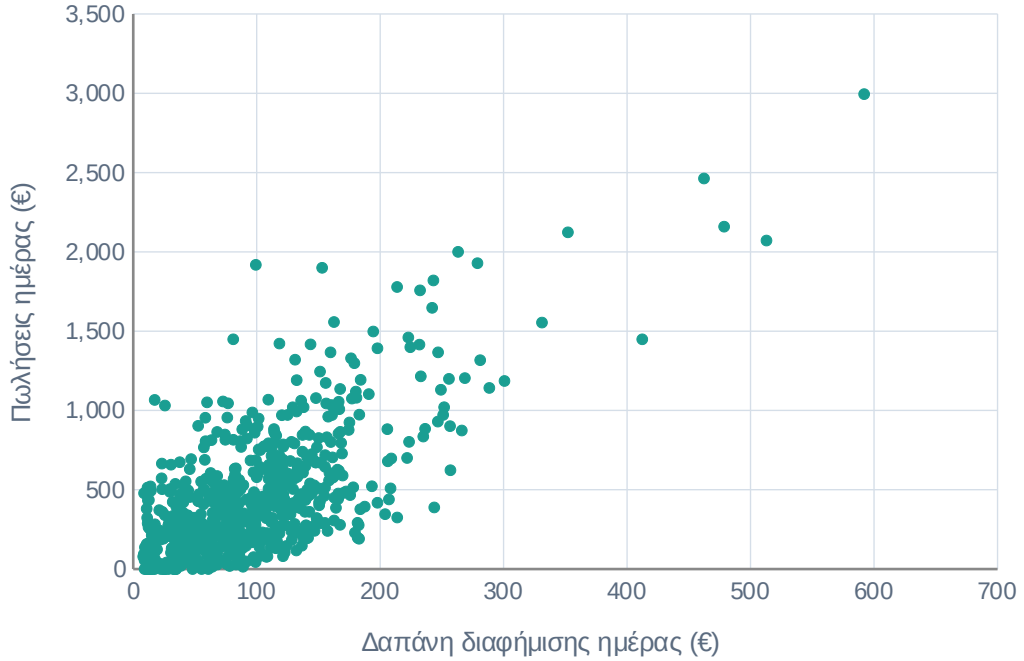
Ζημιογόνα

Αυξάνει τις πωλήσεις, αλλά μειώνει το κέρδος

Γιατί 2; Το περιθώριο μικτού κέρδους της UniStyle είναι ~50% (φύλλο «Σύνοψη»): από κάθε 1 € πωλήσεων μένουν 0,50 €. Για να «βγει» 1 € διαφήμισης, πρέπει να φέρει 2 € πωλήσεις.

Τα δεδομένα: πωλήσεις vs διαφήμιση

731 ημέρες, 2024–2025 · κάθε σημείο είναι μία ημέρα



0.70 συσχέτιση

4.08 κλίση (β_1)

0.49 R^2

Το «σύννεφο» ανεβαίνει προς τα δεξιά. Οι λίγες ημέρες πάνω δεξιά: Black Friday.

Η εκτίμηση στην R

Τέσσερα βήματα

```r
# 1. Διαβάζουμε τα δεδομένα
daily <- read.csv("UniStyle_Daily.csv")

# 2. Μια πρώτη ματιά
head(daily)
summary(daily$Revenue)

# 3. Εκτιμούμε το μοντέλο:  y ~ x
model <- lm(Revenue ~ AdSpend, data = daily)

# 4. Τα αποτελέσματα
summary(model)
```

<- ανάθεση: «βάλε το αποτέλεσμα σε αυτή τη μεταβλητή»

head() οι πρώτες 6 γραμμές = SELECT TOP 6

daily$Revenue η στήλη Revenue του πίνακα daily

lm() = linear model · ο τύπος y ~ x διαβάζεται «y εξηγείται από x»

summary() όλα τα αποτελέσματα σε έναν πίνακα

Διαβάζουμε τα αποτελέσματα

Η ερμηνεία είναι πιο σημαντική από τον κώδικα

ΕΞΟΔΟΣ R (ΣΥΝΤΟΜΕΥΜΕΝΗ)

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  50.4650    18.1552   2.780   0.0056 **
AdSpend       4.0840     0.1550  26.353   <2e-16 ***

Residual standard error: 276 on 729 degrees of freedom
Multiple R-squared: 0.4879,  Adjusted R-squared: 0.4872
F-statistic: 694.5 on 1 and 729 DF,  p-value: < 2.2e-16
```

$\beta_1 = 4.08$

Κάθε επιπλέον 1 € διαφήμισης συνδέεται με 4,08 € περισσότερες πωλήσεις την ίδια ημέρα.

$\beta_0 = 50.47$

Οι «αναμενόμενες» πωλήσεις αν η διαφήμιση ήταν 0 €. Προσοχή: δεν είχαμε ποτέ τέτοια ημέρα (ελάχιστο 8 €).

$R^2 = 0.49$

Η διαφήμιση εξηγεί το 49% των διακυμάνσεων των πωλήσεων. Το υπόλοιπο 51%: εποχή, newsletter, τύχη…

Από το μοντέλο στην πρόβλεψη

Revenue = 50.47 + 4.084 · AdSpend

Πρόβλεψη

Μια ημέρα με 150 € διαφήμιση:

$$50.47 + 4.084 \times 150 \approx 663 \text{ €}$$

Η πρόβλεψη είναι ο μέσος όρος: κάποιες τέτοιες ημέρες θα πουλήσουμε 400 €, άλλες 900 €.

Είναι η σχέση σταθερή;

Περίοδος	β_1	R^2
2024	3.99	0.48
2025	4.16	0.49
Όλο το δείγμα	4.08	0.49

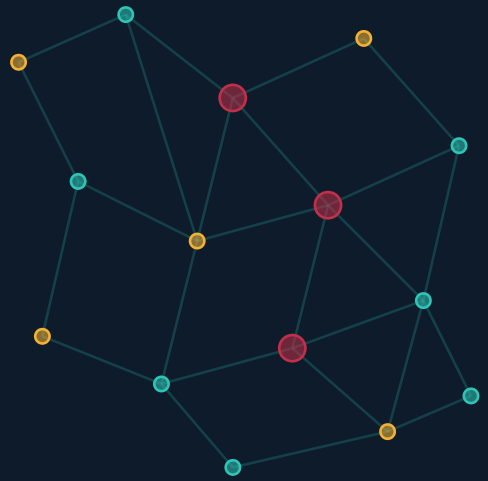
Σχεδόν ίδια κλίση κάθε χρονιά — καλό σημάδι.

Μόνο μέσα στο εύρος των δεδομένων: έχουμε ημέρες με 8 € έως 592 € διαφήμιση. Το μοντέλο δεν λέει τι θα γίνει με 5.000 € την ημέρα.

03

Πολλαπλή παλινδρόμηση

Περισσότερες ερμηνευτικές μεταβλητές — «κρατώντας τα υπόλοιπα σταθερά»



Γιατί περισσότερες μεταβλητές;

$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_k x_k + u$

Καλύτερη εξήγηση: σπάνια ένας παράγοντας εξηγεί μόνος του τις πωλήσεις

Ceteris paribus: το β_1 μετρά την επίδραση του x_1 κρατώντας σταθερά τα $x_2, \ldots, x_k$ — όπως ένα «εικονικό πείραμα»

Μεροληψία παραλειπόμενης μεταβλητής: αν μια σημαντική μεταβλητή λείπει και συσχετίζεται με το x_1, το β_1 «κλέβει» την επίδρασή της

Μεταβλητές 0/1: newsletter, Σαββατοκύριακο, Black Friday — μπαίνουν στο lm() όπως οι αριθμοί (περισσότερα την εβδ. 7)

Παράδειγμα

Τη Black Friday η διαφήμιση είναι 413 € την ημέρα (έναντι 93 € τις άλλες). Τις ημέρες με newsletter, 108 € (έναντι 92 €). Αν εξηγήσουμε τις πωλήσεις μόνο με τη διαφήμιση, η επίδραση της Black Friday και του newsletter «κρύβεται» μέσα στο β της διαφήμισης.

Παράδειγμα: τι εξηγεί τις πωλήσεις;

UniStyle_Daily.csv · 731 ημέρες · εξαρτημένη: Revenue (€)

	Μοντέλο 1	Μοντέλο 2
Σταθερός όρος	50.47	42.99
AdSpend (διαφήμιση, €)	4.084	3.696
Weekend (0/1)	—	−1.84
EmailCampaign (0/1)	—	140.68
BlackFriday (0/1)	—	349.23
Παρατηρήσεις	731	731
R^2	0.488	0.525
Adjusted R^2	0.487	0.523

Τι άλλαξε;

- Το β της διαφήμισης έπεσε από 4,08 σε 3,70
- Μέρος της «επίδρασης της διαφήμισης» ήταν στην πραγματικότητα newsletter και Black Friday
- Το R^2 ανέβηκε από 0,49 σε 0,53

Ερμηνεία & πρόβλεψη

Revenue = 42.99 + 3.696·AdSpend − 1.84·Weekend + 140.68·EmailCampaign + 349.23·BlackFriday

3.696 `AdSpend`

Με όλα τα άλλα ίδια (ίδια ημέρα, ίδιο newsletter), 1 € επιπλέον διαφήμισης συνδέεται με 3,70 € επιπλέον πωλήσεις.

140.68 `EmailCampaign`

Με την ίδια διαφήμιση, μια ημέρα με newsletter έχει κατά μέσο όρο 141 € περισσότερες πωλήσεις.

Πρόβλεψη

Καθημερινή με 150 € διαφήμιση και newsletter (όχι Black Friday):

```
42.99 + 3.696 × 150 + 140.68  ≈  738 €
```

Πολλαπλή παλινδρόμηση στην R

Προσθέτουμε μεταβλητές με +

```r
m1 <- lm(Revenue ~ AdSpend, data = daily)
m2 <- lm(Revenue ~ AdSpend + Weekend +
           EmailCampaign + BlackFriday, data = daily)

summary(m2)
coef(m2)            # μόνο οι συντελεστές

# Πρόβλεψη για μια νέα ημέρα
new_day <- data.frame(AdSpend = 150, Weekend = 0,
                      EmailCampaign = 1, BlackFriday = 0)
predict(m2, newdata = new_day)    # ~738.08
```

+ προσθέτει μεταβλητή · η σειρά δεν παίζει ρόλο

coef() επιστρέφει τα β

predict() εφαρμόζει το μοντέλο σε νέα δεδομένα — η βάση κάθε «μοντέλου πρόβλεψης»

Γέφυρα με το Machine Learning

Η γραμμική παλινδρόμηση είναι το πρώτο «μοντέλο μηχανικής μάθησης» που μαθαίνει κάθε data scientist

	Οικονομετρία	Machine Learning
Στόχος	Εξήγηση: πόσο & γιατί;	Πρόβλεψη: πόσο σωστά;
Το μοντέλο	lm(y ~ x1 + x2)	Linear regression (ίδιο!)
Τι κοιτάμε	β, τυπικά σφάλματα, p-values	Σφάλμα πρόβλεψης σε νέα δεδομένα
Δεδομένα	Όλο το δείγμα	Train set / test set
Επόμενα βήματα	Διαγνωστικοί έλεγχοι (εβδ. 8)	Lasso, Ridge, δέντρα, νευρωνικά δίκτυα

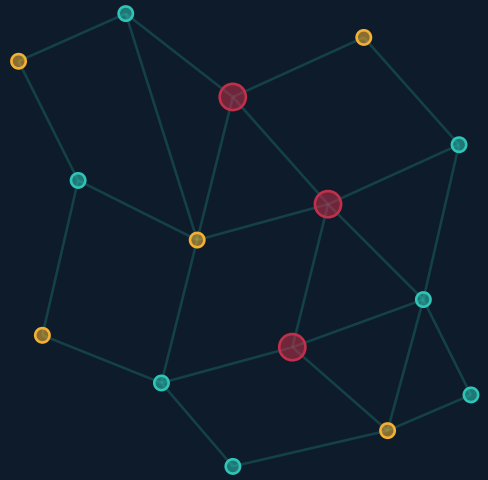


Το predict() που μόλις είδατε είναι ακριβώς ό,τι κάνει ένα μοντέλο ML — απλώς τα πιο σύνθετα μοντέλα «μαθαίνουν» πιο περίπλοκες σχέσεις.

04

Εργαστήριο

Τα πρώτα σας μοντέλα στην R



Ξεκινάμε με το RStudio

Τα αρχεία της εβδομάδας είναι στο eclass

1

Φάκελος

Φτιάξτε φάκελο, π.χ. Documents/BDEA, και αποθηκεύστε εκεί τα UniStyle_Daily.csv και Ebdomada_06.R

2

RStudio

File → Open File → Ebdomada_06.R

3

Φάκελος εργασίας

Session → Set Working Directory → To Source File Location

4

Εκτέλεση

Ctrl + Enter τρέχει τη γραμμή όπου είναι ο κέρσορας · Ctrl + Shift + Enter όλο το script

Ελληνικό Excel: το CSV έχει τελεία για δεκαδικά. Ανοίξτε το με Data → From Text/CSV (Locale: English), αλλιώς οι αριθμοί γίνονται κείμενο. Η R το διαβάζει σωστά.

Ζέσταμα · Γνωρίστε τα δεδομένα

15 λεπτά · UniStyle_Daily.csv · ενότητα 1 του Ebdomada_06.R

α) Με summary() βρείτε μέσο, διάμεσο, ελάχιστο και μέγιστο για Revenue και AdSpend. Γιατί ο μέσος όρος των πωλήσεων είναι πάνω από τον διάμεσο;

β) Τι τύπος δεδομένων είναι το UniStyle_Daily; Και τι τύπος μεταβλητής είναι η καθεμία από τις στήλες του;

γ) Υπολογίστε τις πωλήσεις κάθε μήνα (aggregate) και σχεδιάστε τη χρονοσειρά του 2025. Βλέπετε εποχικότητα;

δ) Υπολογίστε την αυτοσυσχέτιση των ημερήσιων πωλήσεων: cor(σήμερα, χθες)

ΒΟΗΘΕΙΑ

```
monthly <- aggregate(Revenue ~ Year + Month,
                     data = daily, FUN = sum)
m25 <- subset(monthly, Year == 2025)
plot(m25$Month, m25$Revenue, type = "b")

# σήμερα vs χθες
cor(daily$Revenue[-1],
    daily$Revenue[-731])
```

aggregate() = GROUP BY της SQL · [-1] = «όλες εκτός από την πρώτη»

Άσκηση 1 · Πόσες πωλήσεις φέρνει η διαφήμιση;

35 λεπτά · UniStyle_Daily.csv

α) Εκτιμήστε το Revenue ~ AdSpend και επιβεβαιώστε τα νούμερα της διαφάνειας 20

β) Εκτιμήστε το ίδιο μοντέλο χωριστά για το 2024 και το 2025. Είναι η σχέση σταθερή;

γ) Εκτιμήστε Orders ~ AdSpend. Πόσα € διαφήμισης «κοστίζει» κατά μέσο όρο μία επιπλέον παραγγελία; (υπόδειξη: 1 / β_1)

δ) Προβλέψτε τις πωλήσεις μιας ημέρας με 200 € διαφήμιση

ΒΟΗΘΕΙΑ

```
d24 <- subset(daily,
              Year == 2024)
m <- lm(Revenue ~ AdSpend,
        data = d24)
coef(m)
summary(m)$r.squared
```

subset() = WHERE της SQL

Άσκηση 2 · Τι άλλο εξηγεί τις πωλήσεις;

35 λεπτά · UniStyle_Daily.csv

α) Εκτιμήστε τα μοντέλα 1 και 2 της διαφάνειας 24 και επιβεβαιώστε τους αριθμούς

β) Ερμηνεύστε με δικά σας λόγια τους συντελεστές AdSpend και EmailCampaign του μοντέλου 2

γ) Προβλέψτε τις πωλήσεις ενός Σαββάτου με 120 € διαφήμιση, χωρίς newsletter

δ) Εκτιμήστε Revenue ~ Weekend μόνο του. Τι βγαίνει; Γιατί διαφέρει από το μοντέλο 2; (θα το εξετάσουμε στατιστικά την εβδ. 7)

Γέφυρα Excel: ανοίξτε το UniStyle_Daily.csv και υπολογίστε =SLOPE(Revenue; AdSpend). Βγαίνει 4,08 — ίδιο με το μοντέλο 1;

Άσκηση 3 · Challenge

Για όσους τελειώσουν νωρίτερα

OLS «με το χέρι»

Υπολογίστε το β_1 του μοντέλου 1 με τον τύπο Cov(x, y) / Var(x) και το β_0 με $\bar{y} - \beta_1 \cdot \bar{x}$, χρησιμοποιώντας τις cov(), var() και mean(). Βγαίνουν ίδια με το lm();

Google ή social media;

Αντί για AdSpend, βάλτε τα δύο κανάλια χωριστά: lm(Revenue ~ SearchAds + SocialAds). Ποιο κανάλι φαίνεται να αποδίδει περισσότερο; Πιστεύετε το αποτέλεσμα; (θα το εξηγήσουμε την εβδ. 8)

Ανάθεση DataCamp · Εβδομάδα 6

Ολοκλήρωση πριν το επόμενο μάθημα · στο DataCamp Classroom του μαθήματος



Introduction to R

Κεφ. 2 Vectors · Κεφ. 5 Data frames

~1,5 ώρα



Introduction to Regression in R

Κεφ. 1 Simple Linear Regression

~1 ώρα



Σημείωση: το DataCamp χρησιμοποιεί ggplot2 για τα γραφήματα — δεν πειράζει αν δεν το καταλαβαίνετε, δεν θα το χρειαστούμε.

Σύνοψη & επόμενη εβδομάδα

Τι κρατάμε από σήμερα

- Δεδομένα: διαστρωματικά, χρονοσειρά, panel · χρονοσειρά = τάση + εποχικότητα + θόρυβος
- $y = \beta_0 + \beta_1 x + u$ · OLS ελαχιστοποιεί τα τετράγωνα των καταλοίπων
- Μία γραμμή = μία ημέρα: η SQL ετοιμάζει, η R εκτιμά
- $\beta_1 = 4{,}08$: 1 € διαφήμισης ↔ 4,08 € πωλήσεις
- Πολλαπλή: κάθε β «κρατώντας τα υπόλοιπα σταθερά»
- R: lm(y ~ x1 + x2, data = …) και summary()

Εβδομάδα 7

- Είναι το β = 3,70 πραγματικά πάνω από το νεκρό σημείο (2) ή τύχη;
- Έλεγχοι υποθέσεων & t-tests
- p-values: τι σημαίνουν (και τι όχι)
- R^2, adjusted R^2, F-test